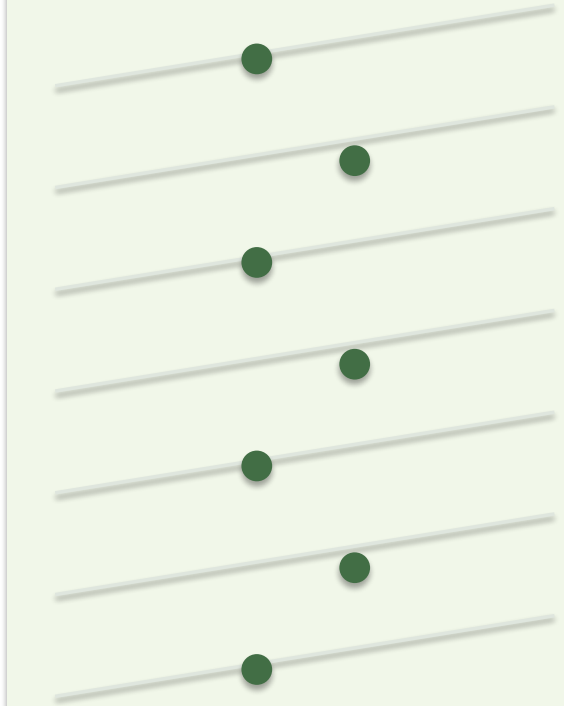
NeRF

Representing Scenes as Neural Radiance Fields for View Synthesis

사진에서 장면으로, 장면에서 새로운 시점으로

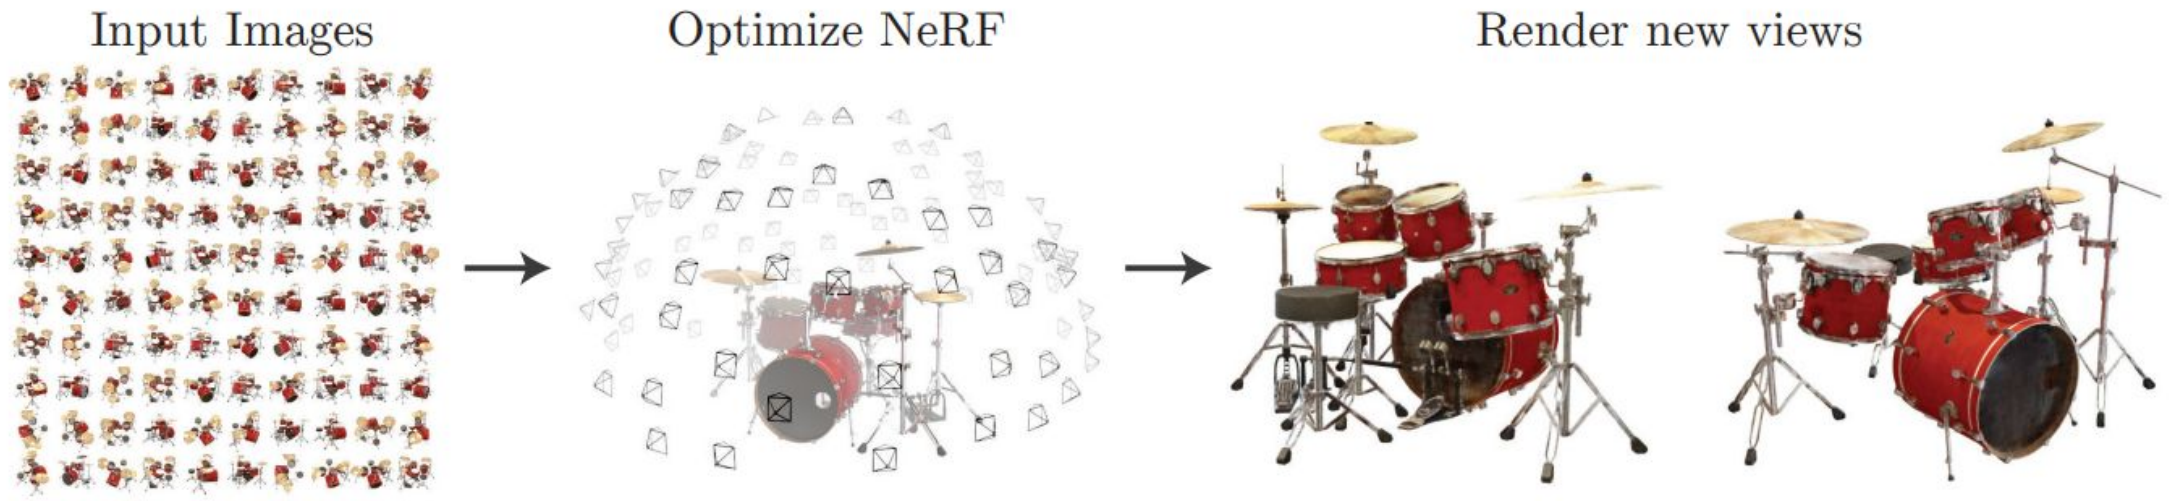
논문 리뷰 · 20–30분



오늘 따라갈 흐름

01 문제	새로운 시점을 만들고 싶다
02 표현	장면을 신경망으로 표현한다
03 렌더링	색과 밀도를 픽셀로 합친다
04 개선·학습	세부 표현과 학습 방식을 살핀다
05 검증	결과와 한계를 확인한다

사진에 없는 시점도 만들 수 있을까?

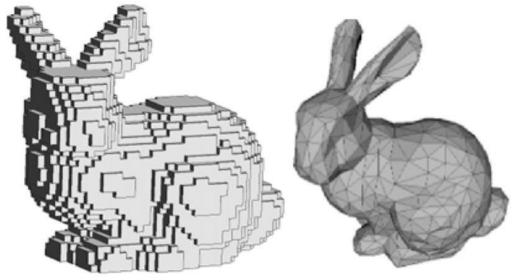


Novel View Synthesis(새로운 시점 합성)

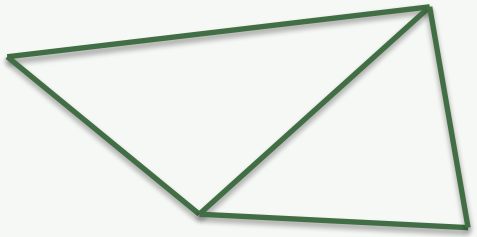
여러 시점의 사진 → 장면 표현 → 촬영하지 않은 시점의 이미지

Source: NeRF Fig. 1 · p. 2

장면을 어떤 형태로 표현할까?

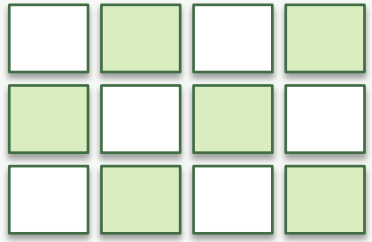


Mesh(메시)



표면을 작은 면들의
연결로 표현

Voxel(복셀)



공간을 작은 격자로
나누어 표현

Neural Field

$$F\Theta(x, d)$$

좌표를 입력하면
장면의 값을 반환

NeRF의 선택: 연속적인 장면 함수를 신경망으로 근사한다.

Source: NeRF §2 · pp. 3–4 | 설명 도식 재구성

신경망에 장면을 물어본다

INPUT

Position(위치) x

Viewing direction(시선 방향) d

MLP

장면을 표현하는 신경망 FΘ

OUTPUT

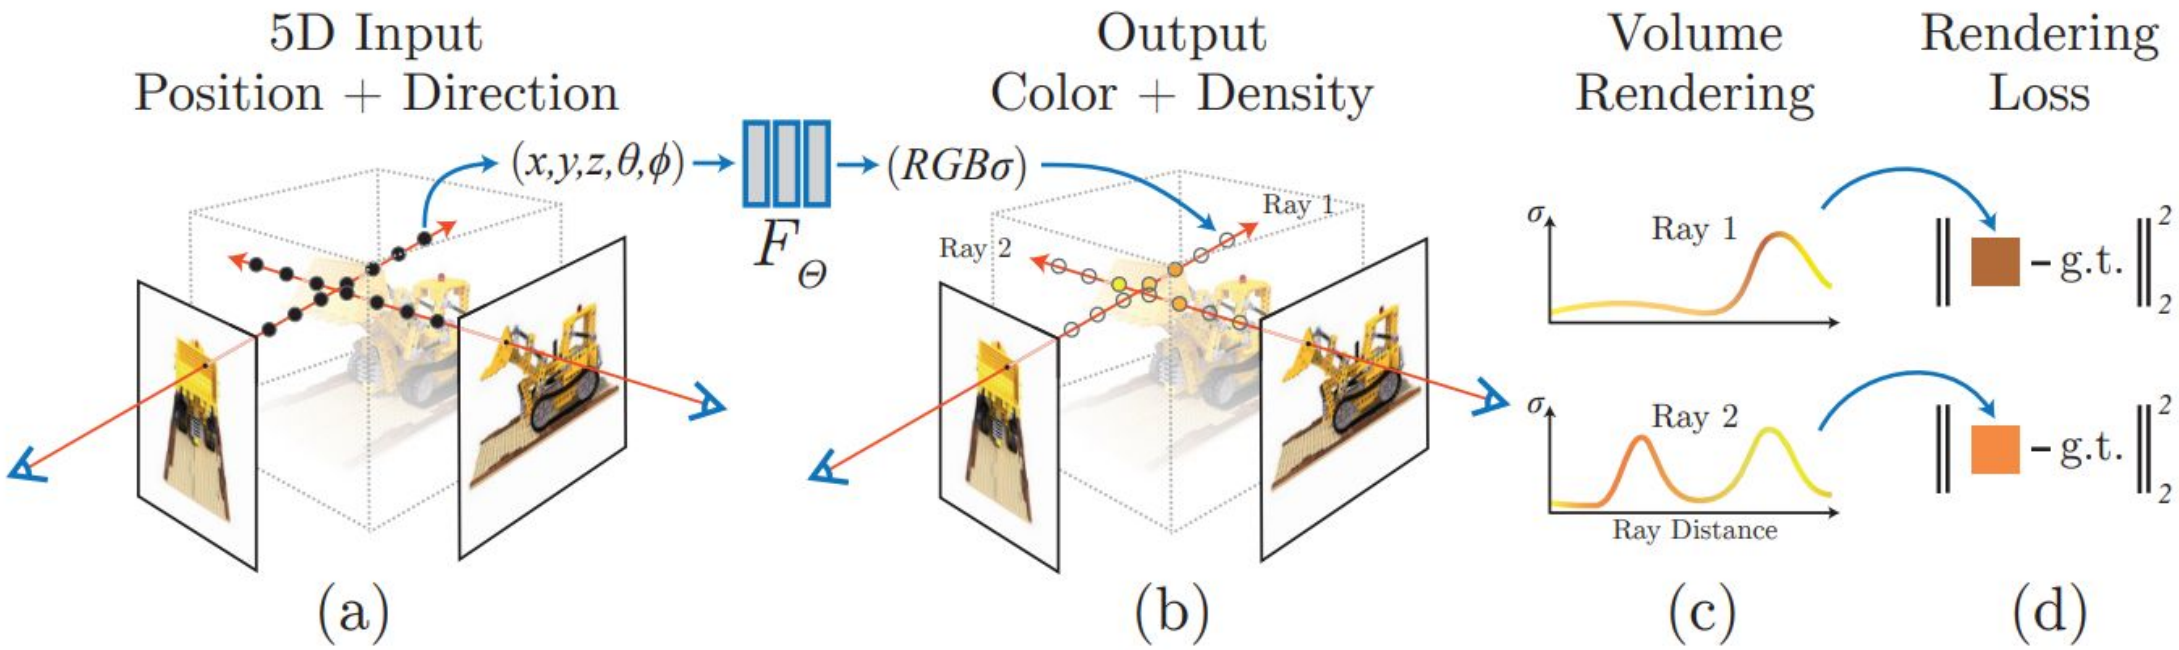
Color(색상) c = RGB

Density(밀도) σ

장면의 정보는 학습된 신경망의 파라미터 Θ 안에 담긴다.

Source: NeRF §3 · pp. 4–5 | 설명 도식 재구성

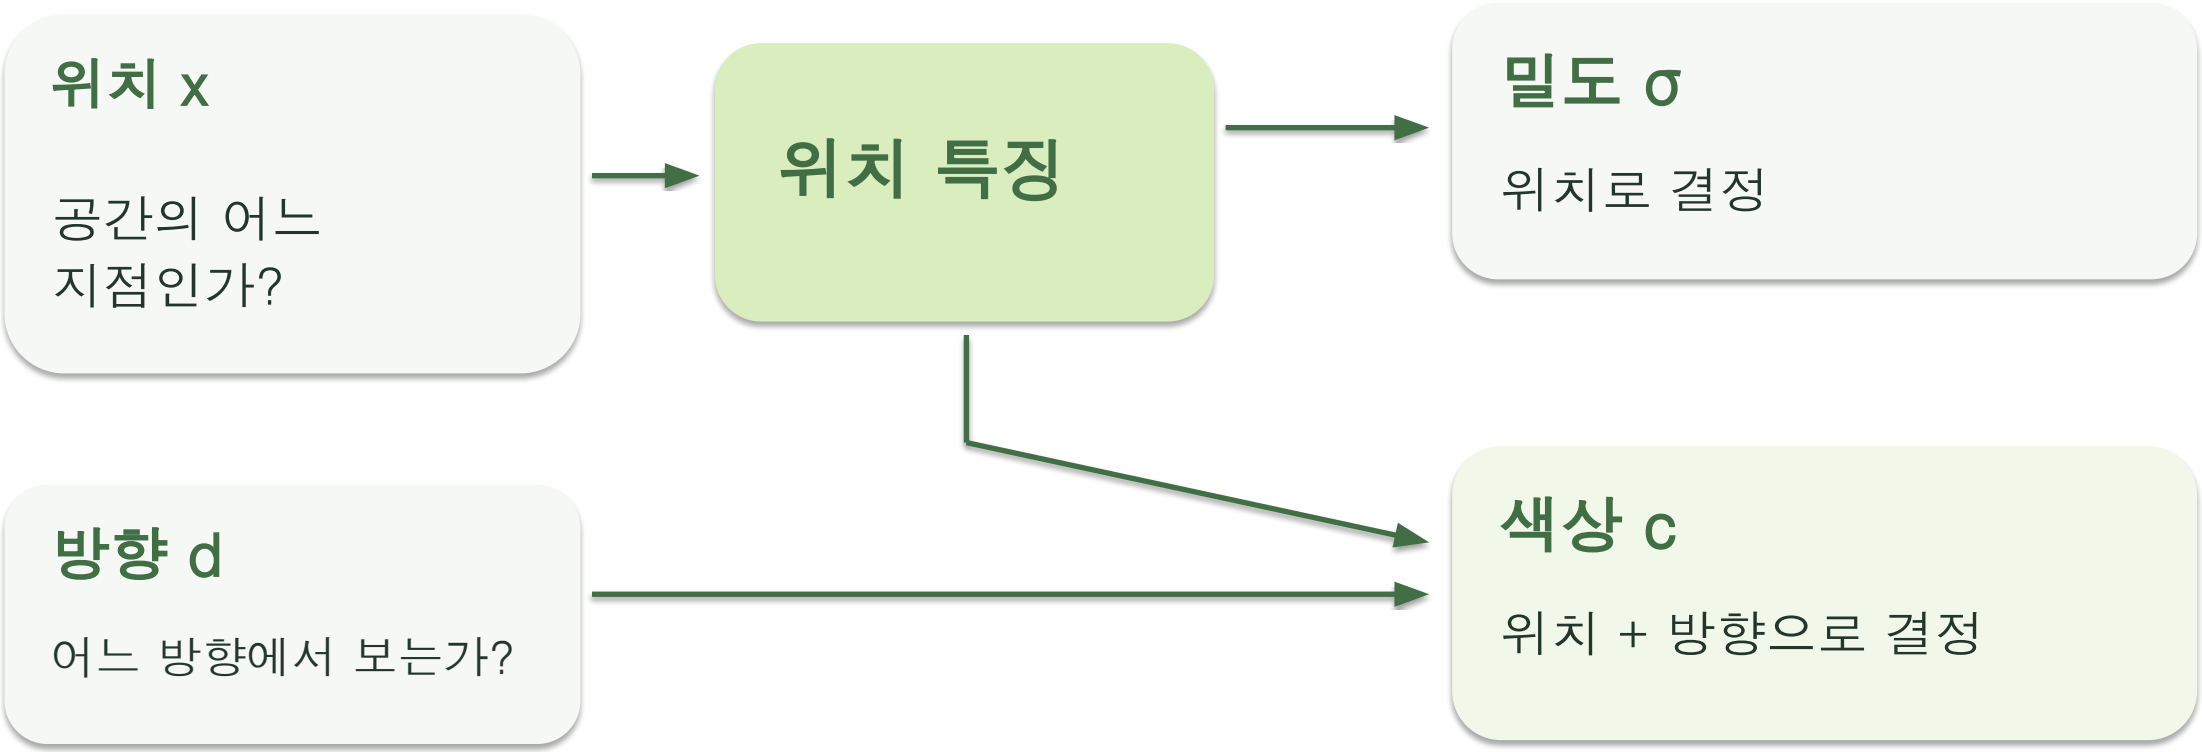
NeRF 전체 파이프라인



① 광선 위의 표본 ② 색·밀도 예측 ③ 픽셀로 합성 ④ 사진과 비교

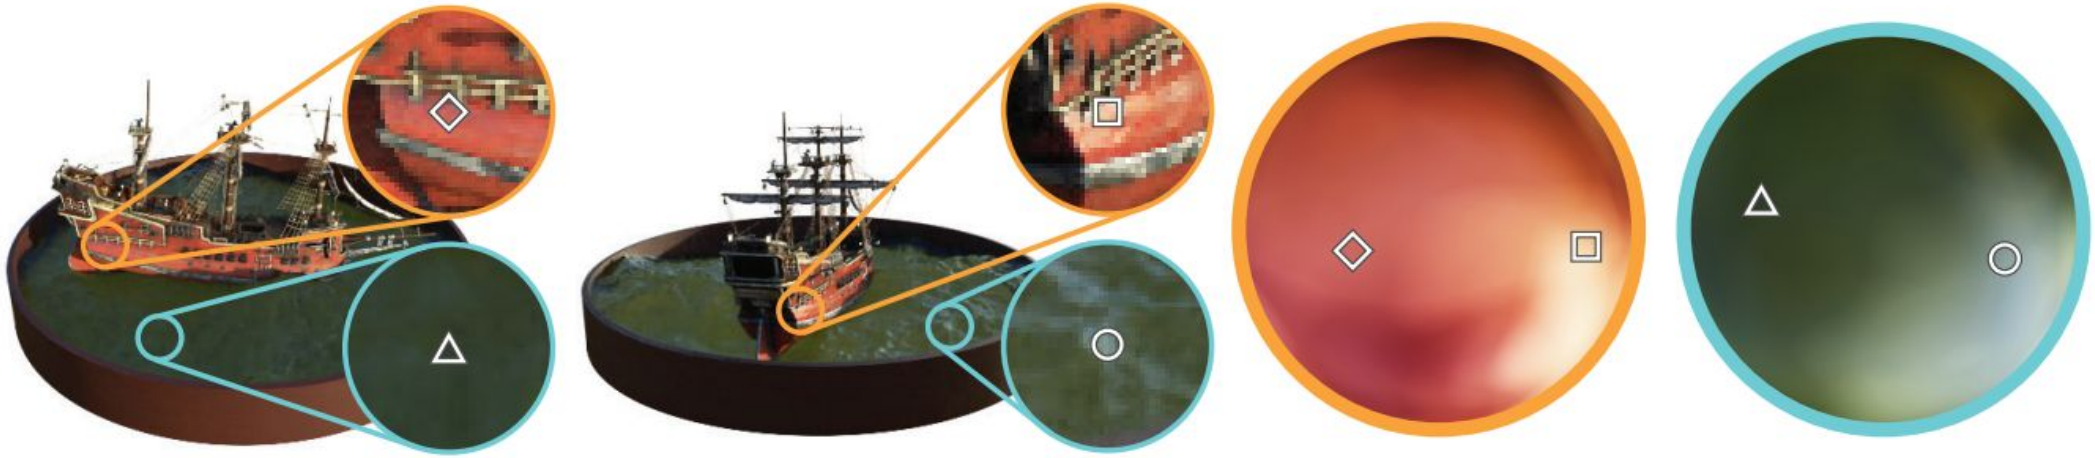
Source: NeRF Fig. 2 · p. 5

위치와 방향은 서로 다른 역할을 한다



Source: NeRF §3 · p. 5 | 네트워크 관계 단순화

같은 지점도 보는 방향에 따라 달라진다



(a) View 1 (b) View 2 (c) Radiance Distributions

같은 위치

물체의 위치는 그대로

달라지는 모습

반사와 밝기는 시점에 따라 변화

Source: NeRF Fig. 3 · p. 6

한 픽셀에서 하나의 광선으로



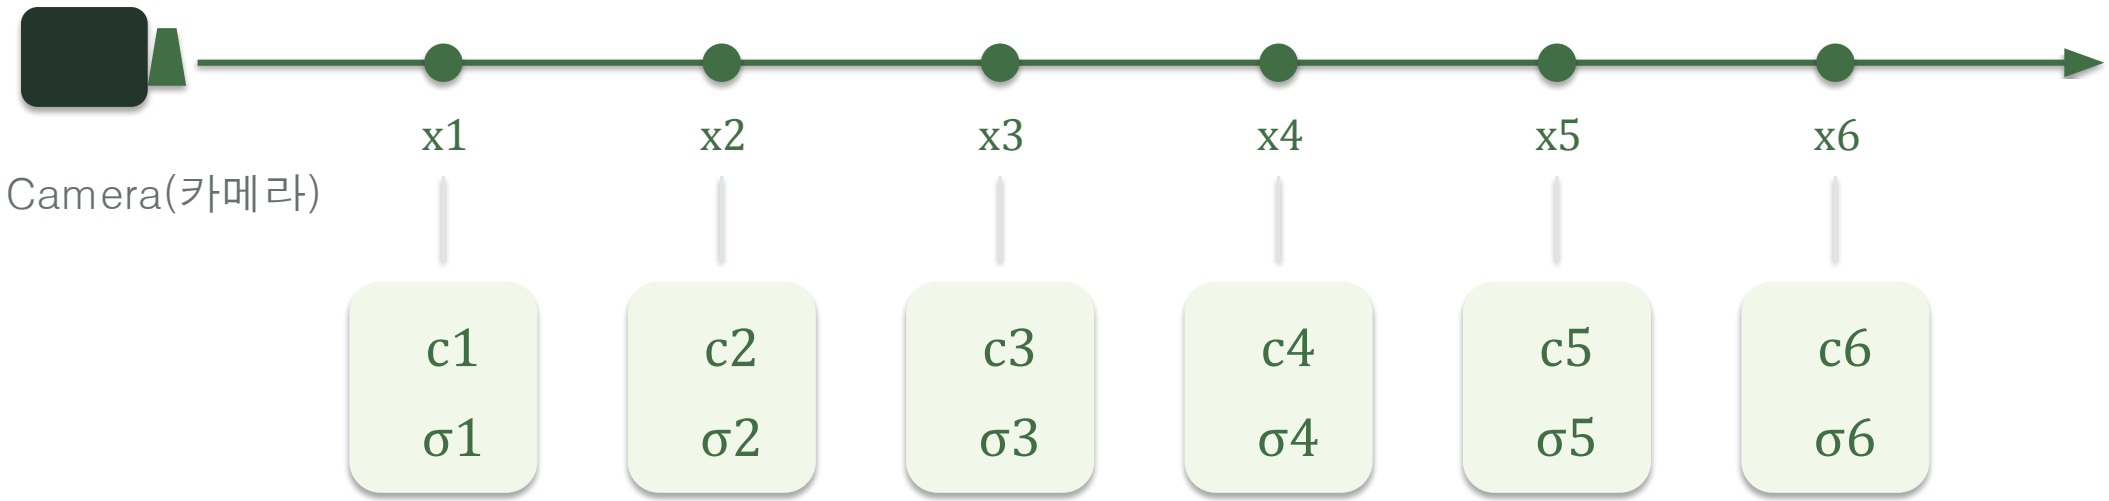
Camera(카메라)

$$\mathbf{r}(t) = \mathbf{o} + t\,\mathbf{d}$$

시작점 o에서 방향 d를 따라 이동하며, 광선 위의 위치를 정한다.

Source: NeRF §4 · Eq. (1) | 설명 도식 재구성

광선 위의 여러 위치를 신경망에 입력한다



각 표본 위치에서 Color(색상)와 Density(밀도)를 얻는다.

그냥 평균이 아니라, 보이는 정도를 반영한다



앞쪽에서 많이 가려지면 뒤쪽의 색은 덜 기여한다.

픽셀 색 = 각 표본의 색 × 그 표본이 기여하는 정도를 누적

Source: NeRF §4 | 개념도이며 실험 결과가 아님

연속적인 광선의 색을 적분한다

$$C\left(r\right) = \int_{t_n}^{t_f} T\left(t\right)\sigma\left(r\left(t\right)\right)c\left(r\left(t\right),d\right)\,dt$$

$$T\left(t\right) = \exp\left(-\int_{t_n}^{t} \sigma\left(r\left(s\right)\right)\,ds\right)$$

c: Color(색상)

위치·방향에서의 색

σ: Density(밀도)

해당 위치의 감쇠 정도

T: Transmittance

앞 구간의 투과율

각 위치의 T × σ × c를 가까운 t□부터 먼 t_f까지 누적한다.

Source: NeRF Eq. (1) · pp. 5–6

실제 계산은 표본 색들의 가중합이다

$$\hat{C}(r) = \sum_{i=1}^{N} w_i c_i, \quad w_i = T_i \alpha_i$$

$$\alpha_i = 1 - \exp(-\sigma_i \delta_i) \qquad T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right)$$

α_i: 해당 구간의 불투명도

$\delta_i = t_{i+1} - t_i$: 표본 간 거리

T_i: 앞쪽 구간들의 투과율

앞 구간의 누적 밀도가 클수록 작아짐

$w_i = T_i \alpha_i$: 그 지점의 색이 최종 픽셀에 얼마나 기여하는가

Source: NeRF Eq. (3), (5) · pp. 6, 8

좌표를 바꿔, 더 세밀한 변화를 표현한다

원래 좌표

p = x, y, z …

좌표 자체를 입력

Positional Encoding

여러 주파수의

sin·cos 값으로 변환

MLP

세밀한 형상·질감의

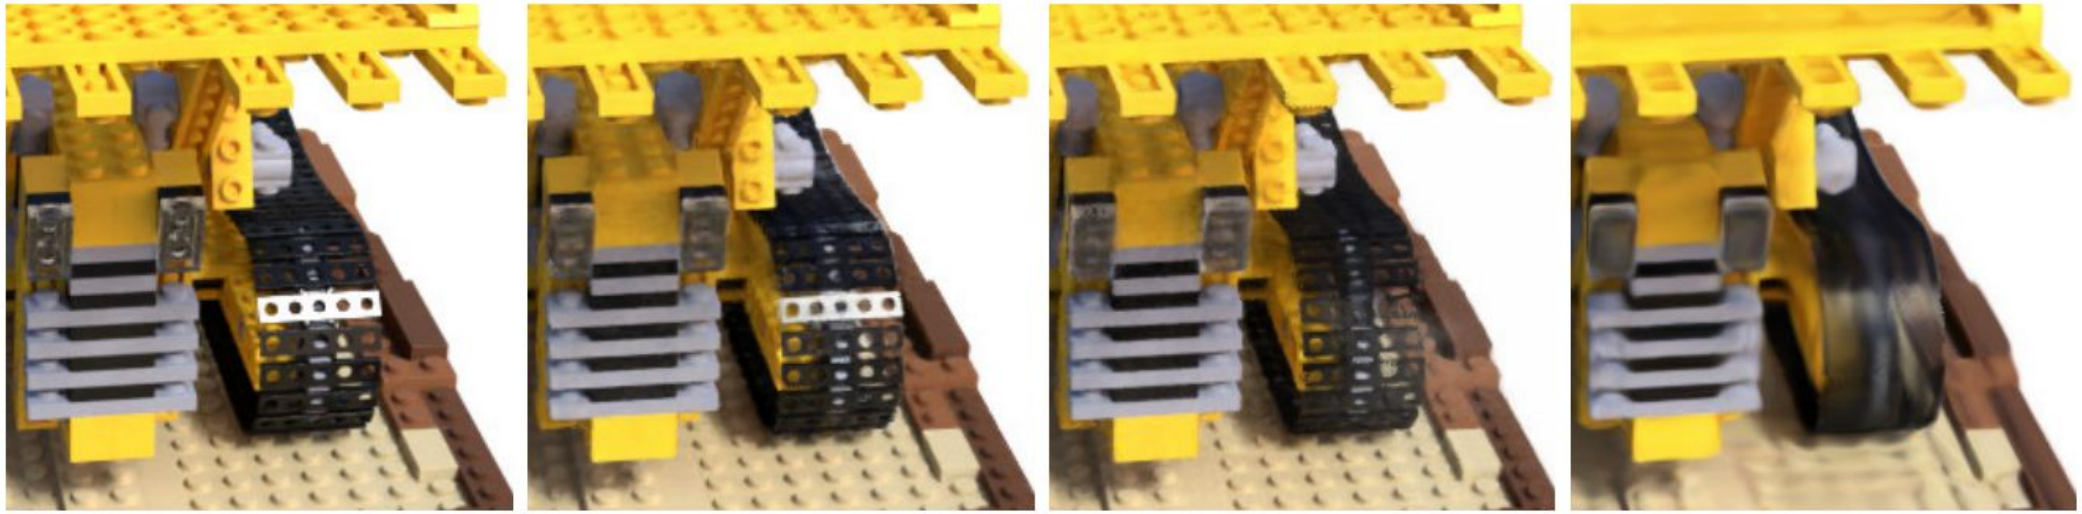
변화를 표현하도록

도움

고주파 변화 = 공간에서 빠르게 바뀌는 무늬와 세부 구조

Source: NeRF §5.1 · Eq. (4) · pp. 7–8

구성요소를 빼면 무엇이 달라질까?



방향 정보 제거

반사 표현이 어려워짐

위치 인코딩 제거

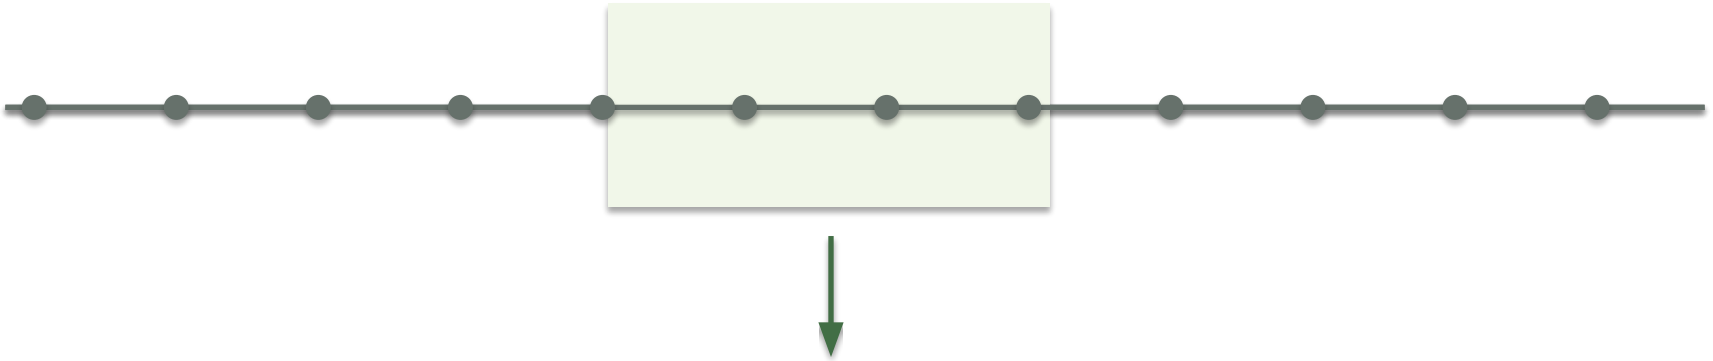
세부 묘사가 흐려짐

Source: NeRF Fig. 4 · p. 7

중요한 영역에 표본을 더 배치한다

Coarse

전체를 먼저 살펴봄



Fine

기여 영역을 더 자세히



Coarse 결과로 분포를 정하고, 추가 표본 + 기존 표본으로 Fine 렌더링

Source: NeRF §5.2 · Eq. (5) · p. 8 | 설명 도식 재구성

실제 사진과 비교하며 장면을 학습한다

렌더링

선택한 카메라에서
픽셀 색 생성

비교

실제 사진의
픽셀 RGB와 비교

조정

오차를 줄이도록
신경망 파라미터
수정

생성 → 비교 → 조정을 반복

Loss: 픽셀 RGB 오차의 제곱합

$$L = \sum_{r \in R} \left[\left\| \hat{C}_c(r) - C(r) \right\|_2^2 + \left\| \hat{C}_f(r) - C(r) \right\|_2^2 \right]$$

C(r)

실제 사진의 RGB

Ĉc(r)

Coarse 렌더링 RGB

Ĉf(r)

Fine 렌더링 RGB

‖예측 RGB − 실제 RGB‖₂ ² = ΔR² + ΔG² + ΔB²

무엇으로 성능을 확인했을까?

Synthetic(합성 장면)

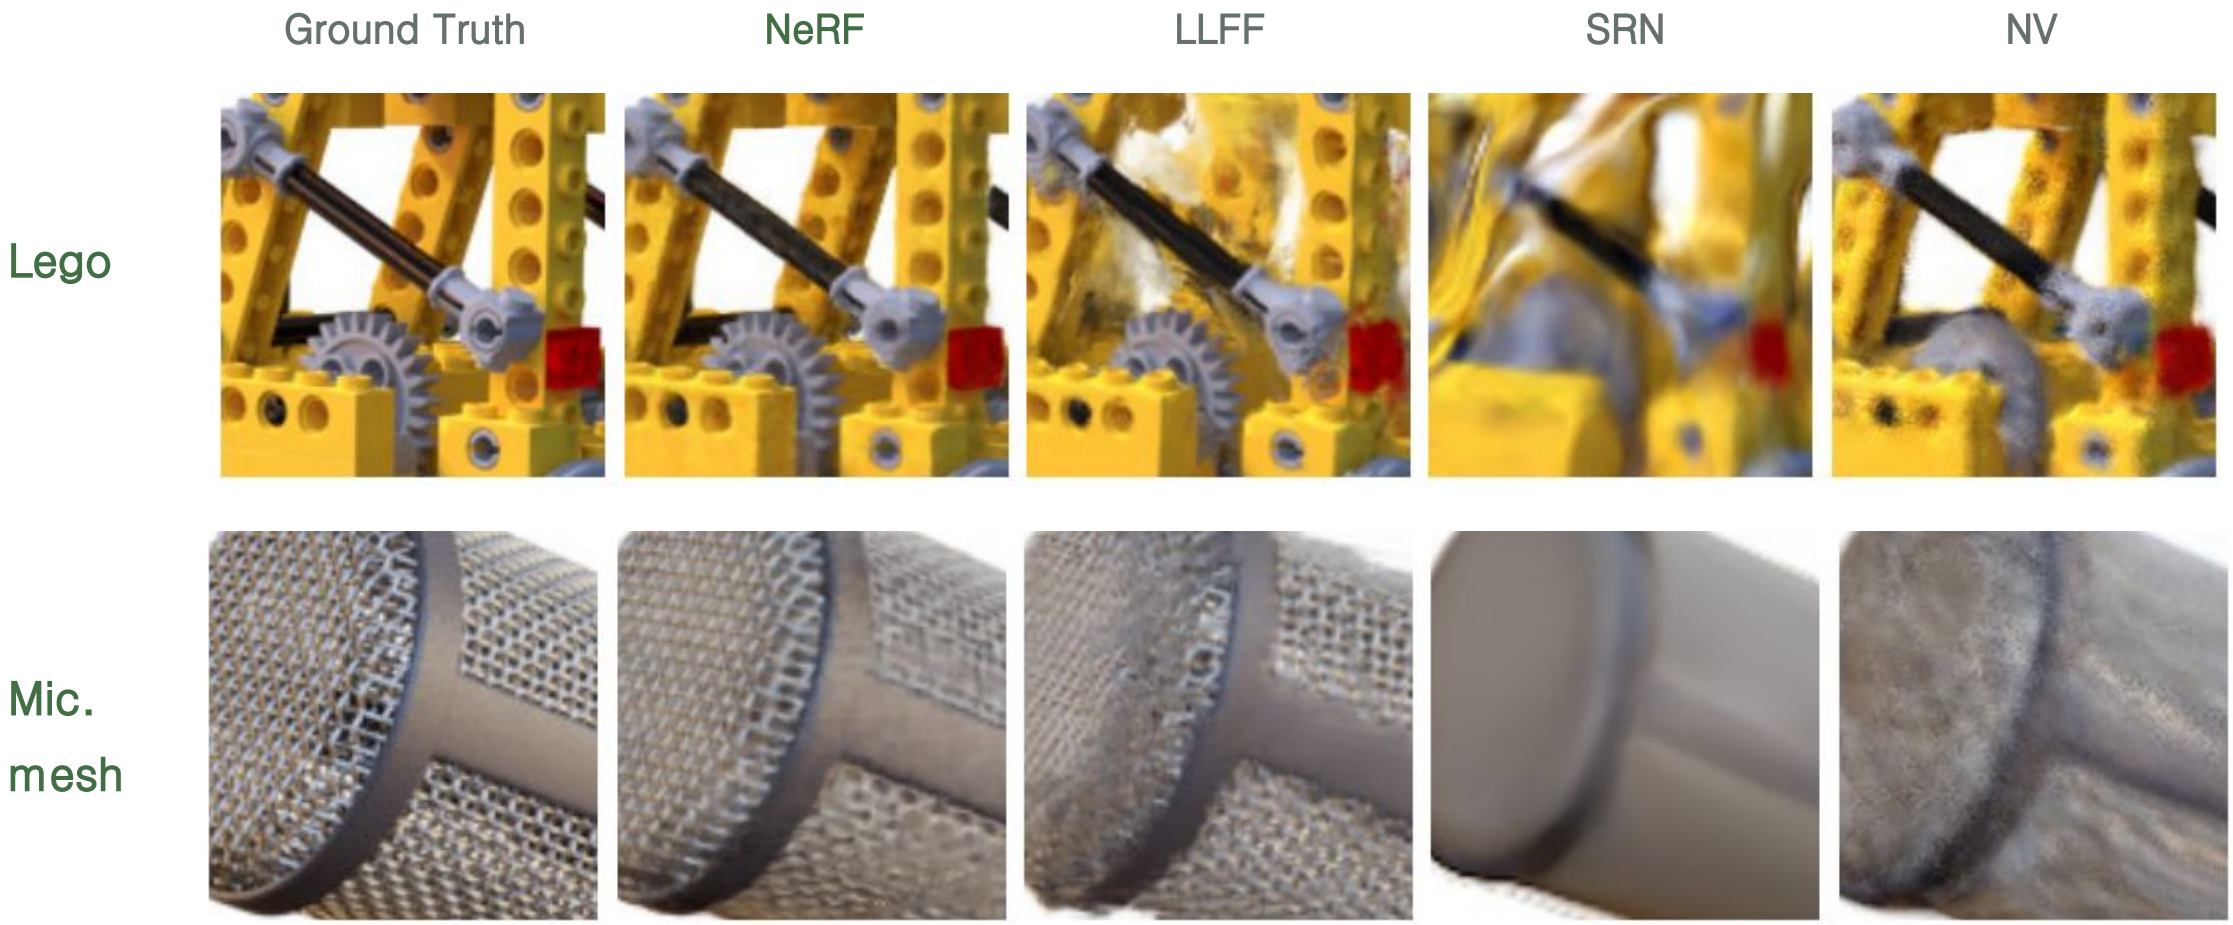
복잡한 형상과 재질을 가진
물체의 새로운 시점

Real(실제 장면)

휴대폰으로 촬영한
실제 환경의 새로운 시점

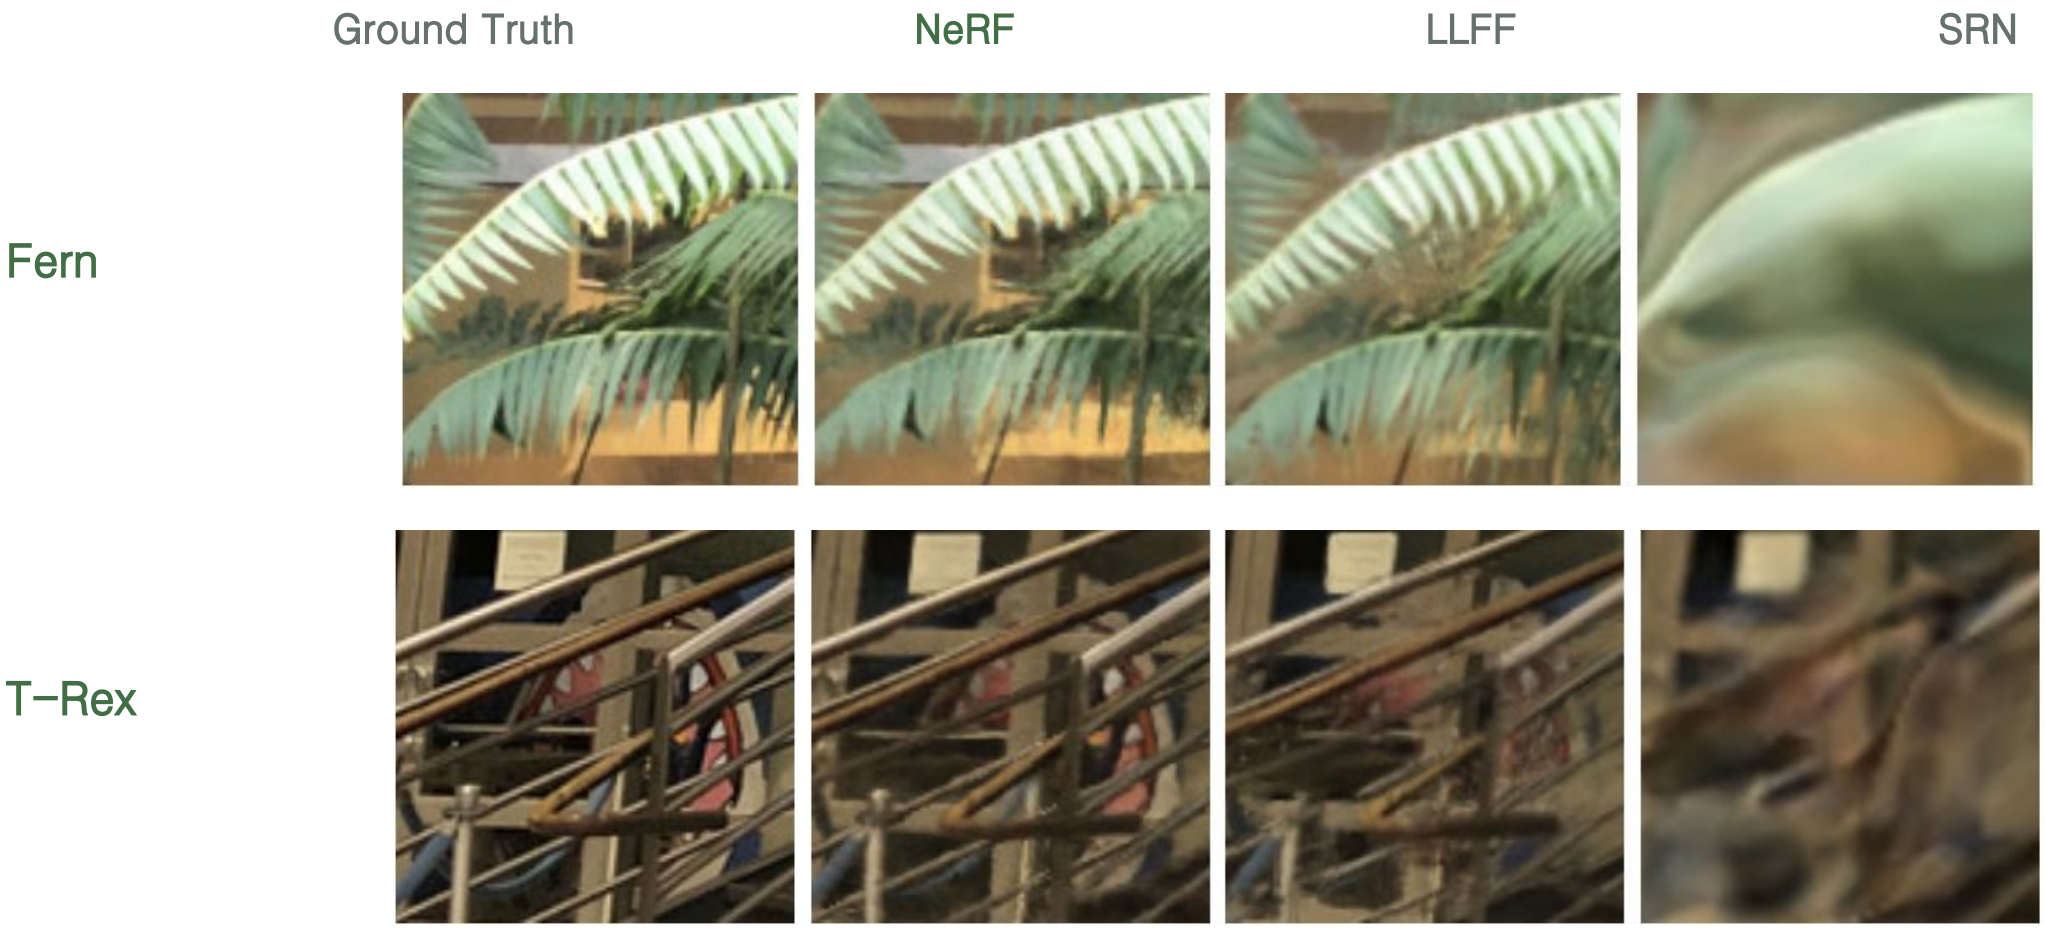
이미지 비교 + PSNR / SSIM / LPIPS

합성 장면: 작은 구조와 질감까지



Source: NeRF Fig. 5 · p. 11 | Lego·Microphone 일부 발췌

실제 장면: 잎과 가느다란 구조



Source: NeRF Fig. 6 · p. 12 | Fern·T-Rex 일부 발췌

정량 결과: 강점과 예외를 함께 보기

Realistic Synthetic 360°

Method	PSNR ↑	SSIM ↑	LPIPS ↓
SRN	22.26	0.846	0.170
NV	26.05	0.893	0.160
LLFF	24.88	0.911	0.114
NeRF	**31.01**	**0.947**	**0.081**

Real Forward-Facing

Method	PSNR ↑	SSIM ↑	LPIPS ↓
SRN	22.84	0.668	0.378
NV	—	—	—
LLFF	24.13	0.798	0.212
NeRF	**26.50**	**0.811**	**0.250**

예외: 실제 LPIPS는 LLFF 0.212 < NeRF 0.250 (낮을수록 좋음)

Source: NeRF Table 1 · p. 10 | 두 데이터군 발췌·재작성

높은 품질, 그러나 계산 부담이 크다

장면별 최적화

새 장면마다 학습

약 1–2일 / 장면

느린 렌더링

많은 신경망 질의

약 30초 / 프레임

기본 설정

정적인 장면

사진·카메라 정보

시간 수치는 원 논문 NVIDIA V100 실험 환경의 보고값

Source: NeRF §5.3, §7, Appendix A · pp. 9, 14, 18

장면을 함수로, 함수를 이미지로

01 **장면 표현** 위치·방향 → 색·밀도

02 **볼륨 렌더링** 광선 위 색들을 기여도에 따라 합성

03 **사진으로 학습** 실제 RGB와 예측 RGB의 제곱오차 최소화

Q&A · 이후 슬라이드는 질문용 부록

Source: Mildenhall et al., NeRF (2020) · arXiv:2003.08934v2

A1. 가중치는 왜 이렇게 정해질까?

모든 구간에서 $\sigma_i\delta_i = \ln 2$라면 $\alpha_i = 0.5$

표본	투과율 T_i	불투명도 α_i	가중치 w_i	색 c_i
1	1	0.5	0.5	Red
2	0.5	0.5	0.25	Green
3	0.25	0.5	0.125	Blue

$\hat{C}$ = 0.5 Red + 0.25 Green + 0.125 Blue

남은 투과율 0.125 · 이 예시는 검은 배경을 가정

Source: NeRF Eq. (1),(3) | 아래 수치는 설명용 예시

A2. RGB 오차가 신경망까지 어떻게 전달될까?

이미지 오차 L

실제 RGB와
예측 RGB 차이

렌더링

표본들의 색·밀도
합성 과정

신경망 Fθ

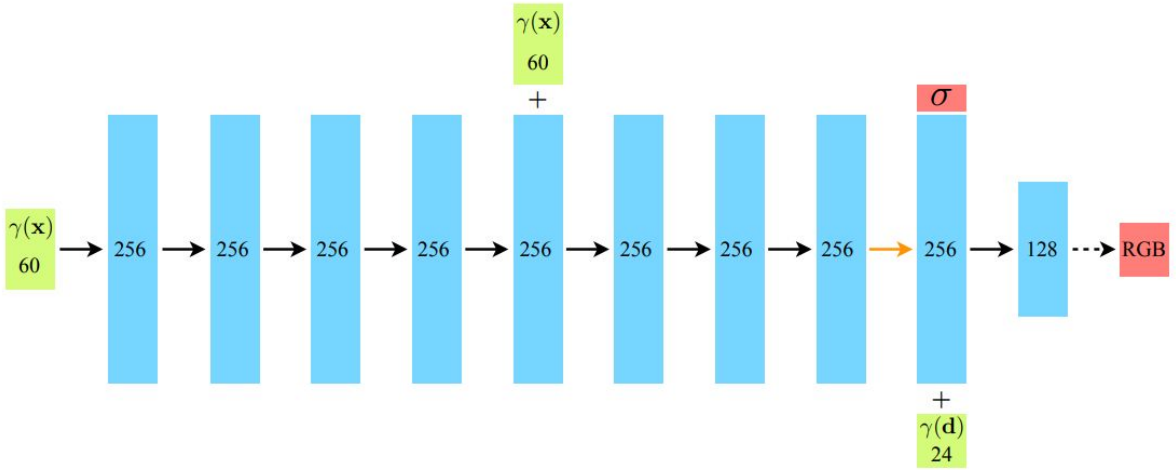
파라미터 θ
업데이트

Coarse에도 오차를 적용해 Fine 표본 분포를 함께 학습

미분 가능한 연결을 따라, 오차가 줄어드는 방향을 계산

Source: NeRF Fig. 2, Eq. (6), §5.3

A3. 원 논문의 MLP 구조



위치 경로

γ(x) → 256채널 층들

밀도 + 중간 특징

색 경로

중간 특징 + γ(d)

128채널 층 → RGB

핵심 구분

밀도: 위치

색상: 위치 + 방향

Source: NeRF Fig. 7 · Appendix A · p. 18

A4. 위치 인코딩은 좌표를 어떻게 바꿀까?

$$\gamma(p) = \left(\sin\left(2^0\pi p\right), \cos\left(2^0\pi p\right), \ \ldots, \sin\left(2^{L-1}\pi p\right), \cos\left(2^{L-1}\pi p\right)\right)$$

한 좌표 p의 변환

L개 주파수의 sin·cos

스칼라 1개 → 2L개 값

원 논문 설정

위치: L = 10

방향: L = 4

여기서는 순서 부여가 아니라, 연속 좌표의 세밀한 변화 표현을 돕는다.

Source: NeRF Eq. (4), §5.1 · pp. 7–8

A5. 표본은 어떤 순서로 선택할까?

01	기본 표본	광선을 구간으로 나누고, 각 구간에서 무작위 위치 선택
02	Coarse 평가	색·밀도로 렌더링 가중치 w_i 계산
03	추가 표본	w_i를 정규화한 분포에서 역변환 샘플링
04	Fine 평가	기존 Nc + 추가 Nf 표본에서 Fine 네트워크 질의

Source: NeRF Eq. (2),(5), §5.2 · pp. 6, 8

A6. 입력 데이터와 비교 조건

학습 입력

RGB + 카메라 자세·내부 파라미터
실제 카메라 정보는 COLMAP으로 추정

대표 데이터 구성

사실적 합성: 학습 100장 / 테스트 200장
실제: 20–62장 중 1/8 테스트

학습 방식의 차이

NeRF·NV·SRN: 장면별 최적화
LLFF: 사전 학습된 모델 활용

평가 해석 주의

SRN: 메모리 제약으로 낮은 해상도
실제 LPIPS: LLFF가 더 좋은 결과

Source: NeRF §5.3, §6.1–6.2, Appendix B · pp. 9–10, 19

A7. 구성요소를 제거한 실험

	Input	#Im.	L	(N_c, N_f)	PSNR↑	SSIM↑	LPIPS↓
1) No PE, VD, H	xyz	100	-	(256, -)	26.67	0.906	0.136
2) No Pos. Encoding	$xyz\theta\phi$	100	-	(64, 128)	28.77	0.924	0.108
3) No View Dependence	xyz	100	10	(64, 128)	27.66	0.925	0.117
4) No Hierarchical	$xyz\theta\phi$	100	10	(256, -)	30.06	0.938	0.109
5) Far Fewer Images	$xyz\theta\phi$	25	10	(64, 128)	27.78	0.925	0.107
6) Fewer Images	$xyz\theta\phi$	50	10	(64, 128)	29.79	0.940	0.096
7) Fewer Frequencies	$xyz\theta\phi$	100	5	(64, 128)	30.59	0.944	0.088
8) More Frequencies	$xyz\theta\phi$	100	15	(64, 128)	30.81	0.946	0.096
9) Complete Model	$xyz\theta\phi$	100	10	(64, 128)	**31.01**	**0.947**	**0.081**

전체 모델

PSNR 31.01

위치 인코딩 제거

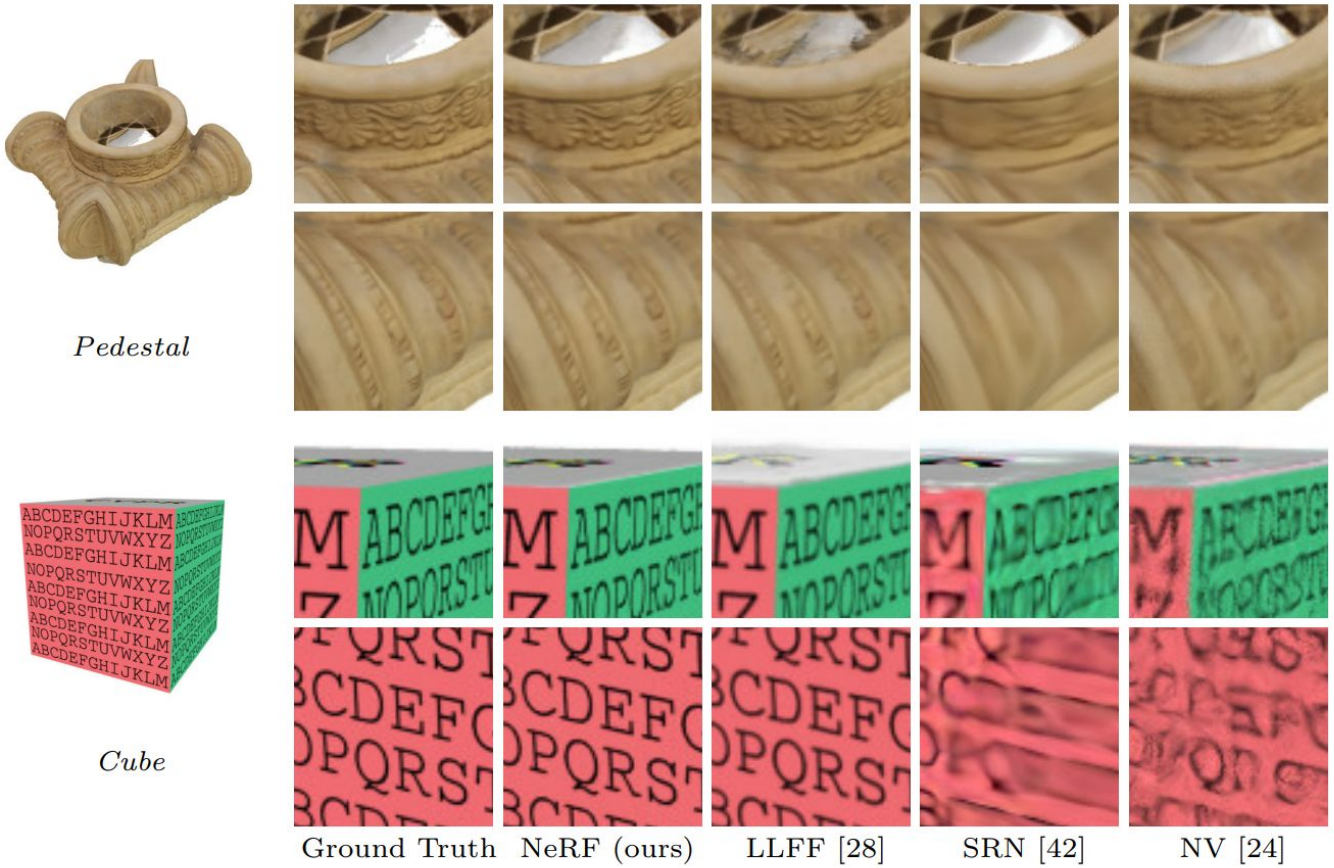
28.77

계층적 샘플링 제거

30.06

Source: NeRF Table 2 · p. 14 | Realistic Synthetic 8 scenes

A8. 단순 합성 장면의 추가 결과



단순 형상 + 확산 반사

입력 이미지 479장

NeRF와 LLFF 모두 매우 높은 재현 성능

복잡한 재질·장면과는 다른 실험 조건

Source: NeRF Fig. 8 · p. 22 | DeepVoxels dataset